

UNIVERSIDADE DE SÃO PAULO

INSTITUTO DE CIÊNCIAS MATEMÁTICAS E DE COMPUTAÇÃO

# **Fundamentos de Probabilidade e Estatística para Ciência de Dados**

Resumo das aulas do Prof. Dr. Francisco Rodrigues

Bruna Zamith Santos

Agosto de 2025

# Sumário

<b>1</b>	<b>Teoria dos Conjuntos</b>	<b>2</b>
<b>2</b>	<b>Experimento Aleatório</b>	<b>2</b>
<b>3</b>	<b>Conceitos de Probabilidade</b>	<b>2</b>
3.1	Probabilidade Frequentista . . . . .	3
3.2	Probabilidade de União de Dois Eventos . . . . .	3
3.3	Probabilidade Condicional . . . . .	3
3.4	Partições do Espaço Amostral . . . . .	3
<b>4</b>	<b>Teorema de Bayes</b>	<b>4</b>
<b>5</b>	<b>Variáveis Aleatórias</b>	<b>4</b>
<b>6</b>	<b>Função de Distribuição</b>	<b>5</b>
<b>7</b>	<b>Esperança</b>	<b>5</b>
7.1	Variável Aleatória Discreta . . . . .	5
7.2	Variável Aleatória Contínua . . . . .	5
7.3	Função de uma Variável Aleatória . . . . .	5
7.4	Propriedades . . . . .	5
<b>8</b>	<b>Momento</b>	<b>6</b>
8.1	Momento Estatístico . . . . .	6
8.2	Momento Central . . . . .	6
<b>9</b>	<b>Variância</b>	<b>6</b>
<b>10</b>	<b>Modelos Probabilísticos (Estocásticos) Discretos</b>	<b>7</b>
10.1	Distribuição Uniforme Discreta . . . . .	7
10.2	Distribuição de Bernoulli . . . . .	7
10.3	Distribuição Binomial . . . . .	8
10.4	Distribuição de Poisson . . . . .	9
10.5	Lei dos Eventos Raros . . . . .	10
10.6	Distribuição Geométrica . . . . .	10
10.7	Distribuição Binomial Negativa . . . . .	11
10.8	Distribuição Hipergeométrica . . . . .	12
<b>11</b>	<b>Modelos Probabilísticos Contínuos</b>	<b>13</b>
11.1	Distribuição Uniforme Contínua . . . . .	13
11.2	Distribuição Normal . . . . .	14
11.3	Distribuição Exponencial . . . . .	15
11.4	Distribuição Gama . . . . .	15
11.5	Distribuição Qui-Quadrado . . . . .	16
11.6	Distribuição Beta . . . . .	17
11.7	Distribuição t de Student . . . . .	18

# 1 Teoria dos Conjuntos

Sejam os conjuntos:

$$A = \{1, 2, 4, 9\}, \quad B = \{3, 7, 9\}$$

- União:  $A \cup B = \{1, 2, 3, 4, 7, 9\}$
- Interseção:  $A \cap B = \{7, 9\}$
- Complementar de  $B$ :  $B^C = \{1, 2, 4\}$
- Complementar de  $A$ :  $A^C = \{3, 7\}$
- Espaço amostral ( $\Omega$ ): É o conjunto de todos os resultados possíveis de um experimento aleatório. Exemplo:  $\Omega = \{1, 2, 3, 4, 5, 6\}$ , ao lançar um dado.
- Evento ( $A$ ): É um subconjunto do espaço amostral. Exemplo:  $A = \{2, 4, 6\}$
- Evento impossível ( $\emptyset$ ): É um evento que nunca ocorre.
- Evento certo ( $\Omega$ ): É o evento que sempre ocorre.
- $A \cup B$ : É o evento que ocorre se  $A$  ou  $B$  (ou ambos) ocorrerem.
- $A \cap B$ : É o evento que ocorre se  $A$  e  $B$  ocorrerem ao mesmo tempo.
- $A^C$ : É o evento que ocorre se  $A$  não ocorre.
- Eventos mutuamente exclusivos: Quando  $A \cap B = \emptyset$ .

## 2 Experimento Aleatório

Um experimento aleatório é um experimento que pode ser repetido inúmeras vezes sob as mesmas condições, sendo o seu resultado incerto.

## 3 Conceitos de Probabilidade

Sejam  $\Omega$  o espaço amostral e  $A$  um evento em  $\Omega$ . Então, uma função  $P(\cdot)$  é denominada probabilidade se satisfaz:

- $0 \leq P(A) \leq 1, \forall A \in \Omega$
- $P(\Omega) = 1$
- Se  $A_1, A_2, \dots$  forem eventos mutuamente exclusivos, isto é,  $A_i \cap A_j = \emptyset, \forall i \neq j$ , então:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

Se um experimento aleatório tiver  $n(\Omega)$  resultados mutuamente exclusivos e igualmente possíveis, e se um evento  $A$  conter  $n(A)$  desses resultados, a probabilidade de ocorrência desse evento é definida por:

$$P(A) = \frac{n(A)}{n(\Omega)} = \frac{|A|}{|\Omega|}$$

Sejam  $A$  e  $B$  eventos em um mesmo espaço amostral, então:

- $P(\emptyset) = 0$
- $P(A) = 1 - P(A^C)$
- Se  $A \subseteq B$ , então  $P(A) \leq P(B)$

### 3.1 Probabilidade Frequentista

A probabilidade de um evento é igual à sua frequência de ocorrência em um grande número de experimentos:

$$P(A) = \lim_{n \rightarrow \infty} \frac{n_A}{n}$$

, onde  $n_A$  é o número de vezes que o evento  $A$  ocorre em  $n$  experimentos.

### 3.2 Probabilidade de União de Dois Eventos

Para dois eventos  $A$  e  $B$  em um mesmo espaço amostral:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

### 3.3 Probabilidade Condicional

Sejam dois eventos  $A$  e  $B$  em um mesmo espaço amostral  $\Omega$ . A probabilidade condicional de  $A$  dado que  $B$  ocorreu é definida por:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}, \quad \text{com } P(B) > 0$$

Assim,  $A$  e  $B$  são eventos independentes se, e somente se:

$$P(A \cap B) = P(A) \cdot P(B)$$

Ou equivalentemente:

$$P(A | B) = P(A) \quad \text{e} \quad P(B | A) = P(B)$$

### 3.4 Partições do Espaço Amostral

Os eventos  $B_1, B_2, \dots, B_n$  formam uma partição do espaço amostral  $\Omega$  se:

- $B_i \cap B_j = \emptyset$ , para  $i \neq j$ , com  $i, j = 1, \dots, n$
- $\bigcup_{i=1}^n B_i = \Omega$
- $P(B_i) \geq 0$ , para  $i = 1, \dots, n$

Seja  $A$  um evento no espaço amostral  $\Omega$  e seja  $B_1, \dots, B_n$  uma partição amostral de  $\Omega$ . Podemos escrever  $A$  considerando tal partição:

$$A = \bigcup_{i=1}^n (A \cap B_i)$$

$$P(A) = P\left(\bigcup_{i=1}^n A \cap B_i\right) = \sum_{i=1}^n P(A \cap B_i)$$

Sejam  $B_1, B_2, \dots, B_n$  uma partição do espaço amostral  $\Omega$ . Então, qualquer evento  $A \subseteq \Omega$  pode ser escrito como:

$$P(A) = \sum_{i=1}^n P(A | B_i) \cdot P(B_i)$$

## 4 Teorema de Bayes

Sejam  $B_1, B_2, \dots, B_n$  uma partição do espaço amostral  $\Omega$ , e  $A$  um evento com  $P(A) > 0$ , então:

$$P(B_i | A) = \frac{P(A | B_i) \cdot P(B_i)}{\sum_{j=1}^n P(A | B_j) \cdot P(B_j)}$$

E assim podemos definir:

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B)}$$

## 5 Variáveis Aleatórias

Suponha que lancemos dois dados. O espaço amostral associado ao experimento, sendo os eventos  $C$ : “sai uma cara” e  $R$ : “sai uma coroa”, é dado por:

$$\Omega = \{CC, CR, RC, RR\}$$

Uma possível variável aleatória associada ao experimento é definida por:

$$X = \text{“número de caras obtido no experimento”}$$

- Representamos variáveis aleatórias por letras maiúsculas ( $X, Y, Z$ ), enquanto usamos letras minúsculas para indicar os valores das variáveis ( $x, y, z$ ).
- Se o número de valores possíveis de uma variável aleatória for finito ou infinito enumerável, dizemos que é uma variável aleatória discreta.
- Caso contrário, é uma variável aleatória contínua.

A função que atribui a cada valor da variável aleatória sua respectiva probabilidade é chamada de distribuição de probabilidade:

$$P(X = x_i) = p(x_i) = p_i, \quad i = 1, 2, 3$$

A distribuição de probabilidade também é chamada de função massa de probabilidade. E temos que:

$$\sum_{i=1}^n P(X = x_i) = 1$$

Dizemos que  $X$  é uma variável aleatória contínua se existir uma função  $f$  denominada função densidade de probabilidade (fdp) que satisfaz:

- $f(x) \geq 0, \quad \forall x \in \mathbb{R}$
- $\int_{-\infty}^{\infty} f(x) dx = 1$
- $P(a \leq X \leq b) = \int_a^b f(x) dx, \quad -\infty < a < b < \infty$
- $f(x)$  é uma função com valores positivos e área unitária.

Seja  $X$  uma variável aleatória discreta ou contínua. A probabilidade condicional de que  $X \in S$  dado que  $X \in V$  é:

$$P(X \in S | X \in V) = \frac{P(X \in S \cap V)}{P(X \in V)}$$

, onde  $S$  e  $V$  são subconjuntos do espaço da variável.

## 6 Função de Distribuição

A função distribuição acumulada ou simplesmente função de distribuição de uma variável aleatória  $X$  é definida por:

$$F(x) = P(X \leq x)$$

Se discreta:

$$F(x) = \sum_{x_i \leq x} P(X = x_i)$$

Se contínua:

$$F(x) = \int_{-\infty}^x f(t) dt$$

Propriedades da função de distribuição:

- $0 \leq F(x) \leq 1$ ,  $F(x)$  é não decrescente,
- $\lim_{x \rightarrow -\infty} F(x) = 0$ ,  $\lim_{x \rightarrow +\infty} F(x) = 1$
- Caso discreto:  $P(a < X \leq b) = F(b) - F(a)$
- Caso contínuo:  $f(x) = \frac{dF(x)}{dx}$

## 7 Esperança

### 7.1 Variável Aleatória Discreta

Seja  $X$  uma variável aleatória discreta com distribuição de probabilidade  $P(X = x_i)$ . O valor esperado (ou esperança matemática) é:

$$E[X] = \sum_{i=1}^n x_i \cdot P(X = x_i)$$

### 7.2 Variável Aleatória Contínua

Seja  $X$  uma variável aleatória contínua com função densidade de probabilidade  $f(x)$ , então:

$$E[X] = \int_{-\infty}^{+\infty} x \cdot f(x) dx$$

### 7.3 Função de uma Variável Aleatória

Seja  $g(X)$  uma função de uma variável aleatória discreta  $X$ . Então:

$$E[g(X)] = \sum_{i=1}^n g(x_i) \cdot P(X = x_i)$$

Seja  $g(X)$  uma função de variável contínua com densidade  $f(x)$ . Então:

$$E[g(X)] = \int_{-\infty}^{\infty} g(x) \cdot f(x) dx$$

### 7.4 Propriedades

- Se  $X = c$ , onde  $c$  é constante, então:  $E[X] = E[c] = c$
- Se  $c$  é constante:  $E[cX] = c \cdot E[X]$

- Então:  $E[aX + b] = a \cdot E[X] + b$

## 8 Momento

### 8.1 Momento Estatístico

Seja  $X$  uma variável aleatória discreta com valores  $x_1, x_2, \dots, x_k$ . O momento de ordem  $n$  de  $X$  é:

$$E[X^n] = \sum_{i=1}^k x_i^n \cdot P(X = x_i)$$

Se  $X$  for contínua:

$$E[X^n] = \int_{-\infty}^{\infty} x^n f(x) dx$$

### 8.2 Momento Central

Seja  $X$  uma variável aleatória.

- Se  $X$  é discreta, o momento central de ordem  $n$  ( $n > 0$ ) de  $X$  é:

$$\mu_n = E[(X - E[X])^n] = \sum_{x_i} (x_i - E[X])^n \cdot P(X = x_i)$$

- Se  $X$  é contínua, então:

$$\mu_n = E[(X - E[X])^n] = \int_{-\infty}^{\infty} (x - E[X])^n \cdot f(x) dx$$

## 9 Variância

A variância de uma variável aleatória  $X$  é definida por:

$$V(X) = \sigma^2 = E[(X - E(X))^2]$$

O desvio padrão é igual à raiz quadrada da variância:

$$\sigma = \sqrt{V(X)}$$

Temos a propriedade de que:

$$V(X) = E[X^2] - (E[X])^2$$

Seja  $g(X)$  uma função da variável aleatória  $X$ . Então,

$$V[g(X)] = E[g(X)^2] - (E[g(X)])^2$$

Seja  $X$  uma variável aleatória e  $a$  e  $b$  constantes. Então,

$$V(aX + b) = a^2 \cdot V(X)$$

## 10 Modelos Probabilísticos (Estocásticos) Discretos

- Os resultados de cada experimento parecem imprevisíveis, mas quando um grande número de experimentos é analisado, surge um padrão.
- Não podemos determinar o valor exato do resultado de um experimento, mas sim as probabilidades de cada resultado possível.

### 10.1 Distribuição Uniforme Discreta

Seja  $X$  uma variável aleatória discreta assumindo os  $n$  valores  $\{a, a + c, a + 2c, \dots, b - c, b\}$ , com  $a, b \in \mathbb{R}$ ,  $c \in \mathbb{R}_{>0}$  e  $a < b$ .

Dizemos que  $X$  segue o modelo uniforme discreto se atribuímos a mesma probabilidade  $1/n$  a cada um desses valores. Isto é, sua distribuição de probabilidade é dada por:

$$P(X = x) = \frac{1}{n}, \quad x = a, a + c, a + 2c, \dots, b$$

onde:

$$n = 1 + \frac{b - a}{c}$$

Então,

$$\mathbb{E}[X] = \frac{a + b}{2},$$

$$V(X) = \frac{c^2(n^2 - 1)}{12}$$

A Figura 1 apresenta um exemplo de Distribuição Uniforme discreta.




Figura 1: Distribuição Uniforme discreta.

### 10.2 Distribuição de Bernoulli

Dizemos que a variável aleatória  $X$  segue o modelo de Bernoulli se atribuímos 0 à ocorrência de um fracasso ou 1 à ocorrência de um sucesso, com  $p$  representando a probabilidade de sucesso,  $0 \leq p \leq 1$ , e  $1 - p$  a probabilidade de fracasso.



A distribuição de probabilidade é dada por:

$$P(X = k) = p^k(1 - p)^{1-k}, \quad k = 0, 1$$

$X$	0	1
$P(X = k)$	$1 - p$	$p$

Então,

$$\mathbb{E}[X] = p,$$

$$V(X) = p \cdot (1 - p)$$

A Figura 2 apresenta um exemplo de Distribuição de Bernoulli.




Figura 2: Distribuição de Bernoulli.

### 10.3 Distribuição Binomial

O processo estocástico de Bernoulli possui as seguintes propriedades:

- O experimento consiste de  $n$  tentativas repetidas;
- Cada tentativa gera um resultado que pode ser classificado como sucesso ou falha;
- A probabilidade de sucesso  $p$  se mantém constante de tentativa para tentativa;
- As tentativas são feitas de forma independente uma da outra.

Seja  $X$  uma variável aleatória baseada em  $n$  repetições de um processo de Bernoulli. Então a probabilidade de obtermos  $k$  sucessos em  $n$  repetições é dada por:

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, 2, \dots, n$$

, onde:

$$C_n^k = \binom{n}{k} = \frac{n!}{(n-k)! k!}$$

é uma combinação de  $n$  elementos tomados de  $k$  em  $k$ .

Então,

$$\mathbb{E}[X] = n \cdot p,$$

$$V(X) = n \cdot p \cdot (1 - p)$$

A Figura 3 apresenta um exemplo de Distribuição Binomial.




Figura 3: Distribuição Binomial.

A seguir, apresentamos um exemplo de problema que pode ser modelado por meio da Distribuição Binomial:

“Uma urna tem 20 bolas pretas e 30 brancas. Retiram-se 25 bolas com reposição. Qual a probabilidade de que 2 sejam pretas?”

## 10.4 Distribuição de Poisson

O processo estocástico de Poisson possui as seguintes propriedades:

- O processo modela a ocorrência de eventos ao longo do tempo ou espaço contínuo;
- Existe uma taxa média constante  $\lambda > 0$ , que representa o número esperado de eventos por unidade de tempo (ou espaço);
- Os eventos ocorrem de forma independente em intervalos disjuntos;
- A probabilidade acumulada de ocorrência de eventos aumenta com o tempo.

Uma variável aleatória discreta  $X$  segue o modelo de Poisson com taxa  $\lambda > 0$  se:

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k = 0, 1, 2, \dots$$

Então,

$$\mathbb{E}[X] = \lambda,$$

$$V(X) = \lambda$$

A Figura 4 apresenta um exemplo de Distribuição de Poisson.




Figura 4: Distribuição de Poisson.

A seguir, apresentamos um exemplo de problema que pode ser modelado por meio da Distribuição de Poisson:

“Numa estrada há 2 acidentes para cada 100 km. Qual a probabilidade de que em 250 km ocorram pelo menos 3 acidentes?”

## 10.5 Lei dos Eventos Raros

Seja  $X$  uma variável aleatória com Distribuição Binomial e  $p$  a probabilidade de sucesso. Então,

$$\lim_{n \rightarrow \infty} \binom{n}{k} p^k (1-p)^{n-k} = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k = 0, 1, 2, \dots,$$

onde  $\lambda = np$  é constante.

## 10.6 Distribuição Geométrica

A Distribuição Geométrica modela o número de tentativas necessárias até a ocorrência do primeiro sucesso em uma sequência de experimentos de Bernoulli independentes. Suas principais características são:

- Cada tentativa resulta em um sucesso (com probabilidade  $p$ ) ou uma falha (com probabilidade  $1 - p$ );
- As tentativas são independentes entre si;
- A variável aleatória  $X$  representa o número de tentativas até o primeiro sucesso (inclusive o sucesso), ou, equivalentemente, o número de falhas antes do primeiro sucesso.

Dizemos que a variável aleatória discreta  $X$  segue uma Distribuição Geométrica se:

$$P(X = k) = p(1-p)^{k-1}, \quad k = 1, 2, \dots$$

Então,

$$\mathbb{E}[X] = \frac{1}{p},$$

$$V(X) = \frac{1-p}{p^2}$$

A Figura 5 apresenta um exemplo de Distribuição Geométrica.




Figura 5: Distribuição Geométrica.

A seguir, apresentamos um exemplo de problema que pode ser modelado por meio da Distribuição Geométrica:

“Suponha que temos uma urna com 36 bolas, sendo 27 bolas brancas e 9 pretas. Bolas são retiradas até que uma bola preta apareça. Qual é a probabilidade de que precisaremos de mais de 6 retiradas para sortear a primeira bola preta?”

## 10.7 Distribuição Binomial Negativa

A Distribuição Binomial Negativa é apropriada para modelar situações em que se deseja saber a probabilidade de que um número fixo de sucessos ocorra na  $k$ -ésima tentativa, ou seja, quantas falhas ocorrem antes de alcançar um número pré-determinado de sucessos.

- Os experimentos são independentes e possuem apenas dois resultados possíveis: sucesso ou falha;
- A probabilidade de sucesso  $p$  é constante em cada tentativa;
- O processo continua até que um número fixo de sucessos seja alcançado.

Seja  $X$  o número de repetições necessárias a fim de que ocorram exatamente  $r$  sucessos, de modo que o  $r$ -ésimo sucesso ocorra na  $k$ -ésima tentativa. Então,

$$P(X = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \quad k = r, r+1, \dots$$

A Figura 6 apresenta um exemplo de Distribuição Binomial Negativa.




Figura 6: Distribuição Binomial Negativa.

A seguir, apresentamos um exemplo de problema que pode ser modelado por meio da Distribuição Binomial Negativa:

“Em uma série da liga de futebol amador de uma cidade, o time que ganhar quatro jogos em sete será o vencedor. Suponha que o time A tenha probabilidade  $p = 0,6$  de ganhar do time B. Qual é a probabilidade de que A vença a série em seis jogos?”

## 10.8 Distribuição Hipergeométrica

A Distribuição Hipergeométrica é semelhante à Distribuição Binomial, porém com uma diferença essencial: as retiradas são feitas sem reposição. Enquanto a Distribuição Binomial assume que cada tentativa é independente e a probabilidade de sucesso permanece constante (devido à reposição), a Distribuição Hipergeométrica modela situações em que a probabilidade de sucesso varia a cada retirada, pois os elementos não são devolvidos ao conjunto.

Considere um conjunto de  $N$  objetos, dos quais  $N_1$  são do tipo 1 e  $N_2 = N - N_1$  são do tipo 2. Para um sorteio de  $n$  objetos ( $n < N$ ), sem reposição, seja  $X$  a variável aleatória que define o número de objetos do tipo 1 sorteados. Então, a probabilidade de sortearmos  $k$  objetos do tipo 1 é:

$$P(X = k) = \frac{\binom{N_1}{k} \binom{N-N_1}{n-k}}{\binom{N}{n}}, \quad k = 0, 1, \dots, n$$

A Figura 7 apresenta um exemplo de Distribuição Hipergeométrica.




Figura 7: Distribuição Hipergeométrica.

A seguir, apresentamos um exemplo de problema que pode ser modelado por meio da Distribuição Hipergeométrica:

“Numa urna há 40 bolas brancas e 60 pretas. Retiram-se 20 bolas. Qual a probabilidade de que ocorram no mínimo 2 bolas brancas, considerando extrações sem reposição?”

## 11 Modelos Probabilísticos Contínuos

### 11.1 Distribuição Uniforme Contínua

Uma variável aleatória contínua  $X$  segue uma Distribuição Uniforme se sua função densidade de probabilidade é dada por:

$$f(x) = \begin{cases} \frac{1}{b-a}, & x \in [a, b] \\ 0, & x \notin [a, b] \end{cases}$$

Então,

$$\mathbb{E}[X] = \frac{a+b}{2},$$

$$V(X) = \frac{(b-a)^2}{12}$$

A Figura 8 apresenta um exemplo de Distribuição Uniforme contínua.




Figura 8: Distribuição Uniforme contínua.

## 11.2 Distribuição Normal

Uma variável aleatória contínua  $X$  que tome todos os valores na reta real segue a Distribuição Normal (ou Gaussiana) se sua função densidade de probabilidade é definida por:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[ -\frac{1}{2} \left( \frac{x - \mu}{\sigma} \right)^2 \right], \quad -\infty < x < \infty$$

onde  $\mu = E[X]$  e  $\sigma^2 = V(X) > 0$ .

A Distribuição Normal apresenta as seguintes propriedades:

- $f(x)$  é simétrica em relação à  $\mu$ .
- $f(x) \rightarrow 0$  quando  $x \rightarrow \pm\infty$ .
- O valor máximo de  $f(x)$  ocorre em  $x = \mu$ .

Se  $X$  é uma variável aleatória contínua com distribuição normal,  $X \sim \mathcal{N}(\mu, \sigma^2)$ , e se  $Y = aX + b$ , com  $a$  e  $b$  constantes, então

$$Y \sim \mathcal{N}(a\mu + b, a^2\sigma^2).$$

Seja  $X \sim \mathcal{N}(\mu, \sigma^2)$ . Se

$$Z = \frac{X - \mu}{\sigma},$$

então  $Z \sim \mathcal{N}(0, 1)$ .

Assim,

$$\begin{aligned} P(a \leq X \leq b) &= P\left(\frac{a - \mu}{\sigma} \leq \frac{X - \mu}{\sigma} \leq \frac{b - \mu}{\sigma}\right) \\ &= P\left(\frac{a - \mu}{\sigma} \leq Z \leq \frac{b - \mu}{\sigma}\right) \\ &= P(X \leq b) - P(X \leq a). \end{aligned}$$

A tabela Normal pode ser acessada através do link [https://en.wikipedia.org/wiki/Standard\\_normal\\_table#Table\\_examples](https://en.wikipedia.org/wiki/Standard_normal_table#Table_examples).

A Figura 9 apresenta um exemplo de Distribuição Normal.




Figura 9: Distribuição Normal.

### 11.3 Distribuição Exponencial

Uma variável aleatória contínua  $X$  segue o modelo exponencial se sua função densidade de probabilidade é dada por:

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

onde  $\lambda > 0$  e  $-\infty < x < \infty$ .

Então,

$$E[X] = \frac{1}{\lambda},$$

$$V(X) = \frac{1}{\lambda^2}$$

A Distribuição Exponencial apresenta a propriedade de “ausência de memória”, isto é:

$$P(X \geq t + s \mid X \geq s) = P(X \geq t)$$

A Figura 10 apresenta um exemplo de Distribuição Exponencial.

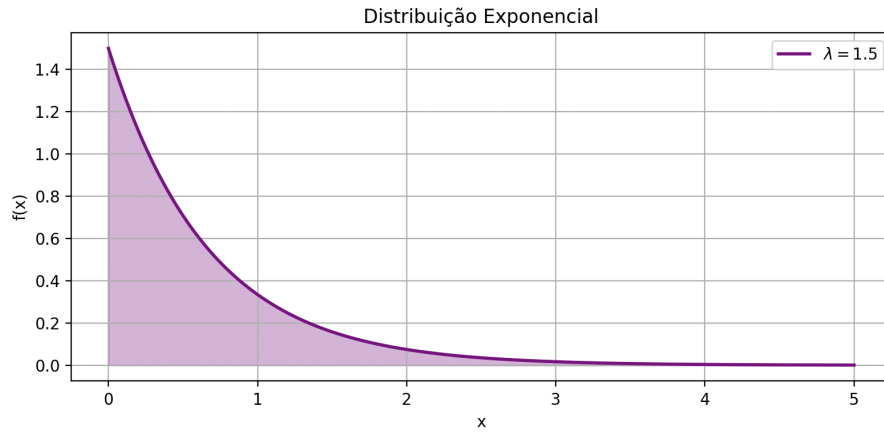


Figura 10: Distribuição Exponencial.

### 11.4 Distribuição Gama

Uma variável aleatória contínua  $X$  tem Distribuição Gama com parâmetros  $\lambda > 0$  e  $\alpha > 0$ , se sua função densidade de probabilidade é dada por:

$$f(x) = \begin{cases} \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0, \end{cases}$$

onde  $\Gamma$  é a função gama:

$$\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt.$$

Então,

$$E[X] = \frac{\alpha}{\lambda},$$

$$V(X) = \frac{\alpha}{\lambda^2}$$

Se  $\alpha$  for um número inteiro positivo, a distribuição representará uma distribuição Erlang, ou seja, a soma de  $\alpha$  variáveis aleatórias independentes distribuídas exponencialmente, cada uma delas com uma



média  $\theta = 1/\lambda$ .

A Figura 11 apresenta um exemplo de Distribuição Gama.




Figura 11: Distribuição Gama.

## 11.5 Distribuição Qui-Quadrado

A variável aleatória contínua  $X$  segue a Distribuição Qui-Quadrado (denominada  $\chi^2$ ) se sua função densidade de probabilidade é dada por:

$$f(x) = \begin{cases} \frac{x^{k/2-1} e^{-x/2}}{2^{k/2} \Gamma(k/2)}, & x > 0, \\ 0, & x \leq 0, \end{cases}$$

A Distribuição Qui-Quadrado é definida pela soma de  $k$  distribuições normais padronizadas e independentes. Ou seja,  $X$  tem Distribuição Qui-Quadrado com  $k$  graus de liberdade se

$$X = \sum_{i=1}^k Z_i^2,$$

onde  $Z_1, Z_2, \dots, Z_k$  são variáveis aleatórias com distribuição normal padronizada,

$$Z_i \sim \mathcal{N}(\mu = 0, \sigma^2 = 1), \quad i = 1, \dots, k.$$

Para denominar que  $X$  segue uma Distribuição Qui-Quadrado, usamos  $X \sim \chi^2(k)$  ou  $X \sim \chi_k^2$ .

A Figura 12 apresenta um exemplo de Distribuição Qui-Quadrado.

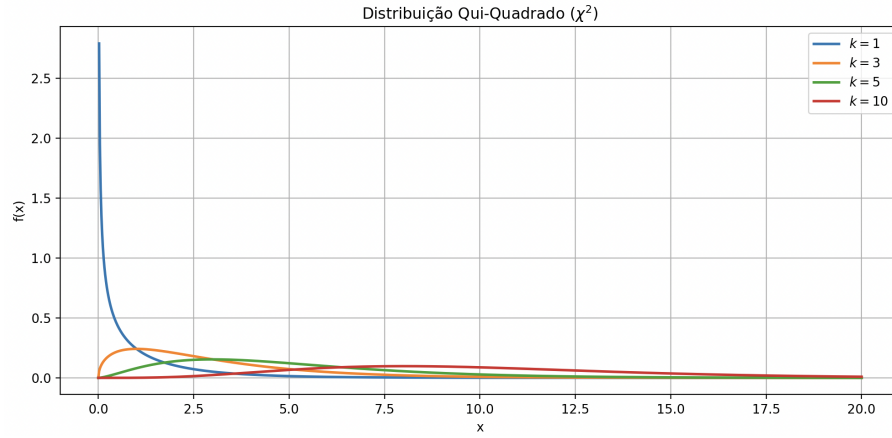


Figura 12: Distribuição Qui-Quadrado.

## 11.6 Distribuição Beta

Seja  $X$  uma variável aleatória contínua limitada em  $[0, 1]$ . Dizemos que  $X$  segue uma Distribuição Beta se sua função densidade de probabilidade é dada por:

$$f(x) = \begin{cases} \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}, & 0 < x < 1, \\ 0, & \text{caso contrário,} \end{cases}$$

onde  $\alpha, \beta > 0$  e

$$B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-u)^{\beta-1} du,$$

é a função beta, que atua como uma constante de normalização para que a área da função densidade de probabilidade seja igual a um.

A Figura 13 apresenta um exemplo de Distribuição Beta.

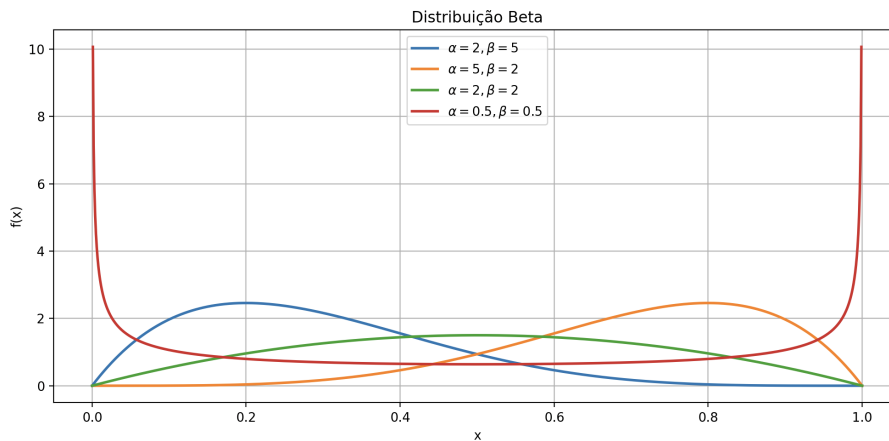


Figura 13: Distribuição Beta.

## 11.7 Distribuição t de Student

A variável aleatória  $X$  tem Distribuição t de Student com  $\nu$  graus de liberdade se sua função densidade de probabilidade é dada por:

$$f(x) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}, \quad -\infty < x < \infty$$

onde  $\Gamma$  é a função gama:

$$\Gamma(\alpha) = \int_0^{\infty} t^{\alpha-1} e^{-t} dt$$

Quando aumentamos  $\nu$ , a distribuição se aproxima da Distribuição Normal.

A Figura 14 apresenta um exemplo de Distribuição t de Student.




Figura 14: Distribuição t de Student.