

UNIVERSIDADE DE SÃO PAULO

INSTITUTO DE CIÊNCIAS MATEMÁTICAS E DE COMPUTAÇÃO

Fundamentos de Probabilidade e Estatística para Ciência de Dados

Resumo das aulas do Prof. Dr. Francisco Rodrigues

Bruna Zamith Santos

Agosto de 2025

Sumário

1	Teoria dos Conjuntos	3
2	Experimento Aleatório	3
3	Conceitos de Probabilidade	3
3.1	Probabilidade Frequentista	4
3.2	Probabilidade de União de Dois Eventos	4
3.3	Probabilidade Condicional	4
3.4	Partições do Espaço Amostral	4
4	Teorema de Bayes	5
5	Variáveis Aleatórias	5
6	Função de Distribuição	6
7	Esperança	6
7.1	Variável Aleatória Discreta	6
7.2	Variável Aleatória Contínua	6
7.3	Função de uma Variável Aleatória	6
7.4	Propriedades	6
8	Momento	7
8.1	Momento Estatístico	7
8.2	Momento Central	7
9	Variância	7
10	Modelos Probabilísticos (Estocásticos) Discretos	8
10.1	Distribuição Uniforme Discreta	8
10.2	Distribuição de Bernoulli	8
10.3	Distribuição Binomial	9
10.4	Distribuição de Poisson	10
10.5	Lei dos Eventos Raros	11
10.6	Distribuição Geométrica	11
10.7	Distribuição Binomial Negativa	12
10.8	Distribuição Hipergeométrica	13
11	Modelos Probabilísticos Contínuos	13
11.1	Distribuição Uniforme Contínua	13
11.2	Distribuição Normal	14
11.3	Distribuição Exponencial	15
11.4	Distribuição Gama	16
11.5	Distribuição Qui-Quadrado	17
11.6	Distribuição Beta	17
11.7	Distribuição t de Student	18
11.8	Distribuição Weibull	18

12 Variáveis Aleatórias Multidimensionais	19
12.1 Discretas	19
12.2 Contínuas	19
12.3 Distribuição de Probabilidade Marginal	20
12.4 Probabilidade Condicional Discreta	20
12.5 Probabilidade Condicional Contínua	20
12.6 Independência	20

1 Teoria dos Conjuntos

Sejam os conjuntos:

$$A = \{1, 2, 4, 9\}, \quad B = \{3, 7, 9\}$$

- União: $A \cup B = \{1, 2, 3, 4, 7, 9\}$
- Interseção: $A \cap B = \{7, 9\}$
- Complementar de B : $B^C = \{1, 2, 4\}$
- Complementar de A : $A^C = \{3, 7\}$
- Espaço amostral (Ω): É o conjunto de todos os resultados possíveis de um experimento aleatório. Exemplo: $\Omega = \{1, 2, 3, 4, 5, 6\}$, ao lançar um dado.
- Evento (A): É um subconjunto do espaço amostral. Exemplo: $A = \{2, 4, 6\}$
- Evento impossível (\emptyset): É um evento que nunca ocorre.
- Evento certo (Ω): É o evento que sempre ocorre.
- $A \cup B$: É o evento que ocorre se A ou B (ou ambos) ocorrerem.
- $A \cap B$: É o evento que ocorre se A e B ocorrerem ao mesmo tempo.
- A^C : É o evento que ocorre se A não ocorre.
- Eventos mutuamente exclusivos: Quando $A \cap B = \emptyset$.

2 Experimento Aleatório

Um experimento aleatório é um experimento que pode ser repetido inúmeras vezes sob as mesmas condições, sendo o seu resultado incerto.

3 Conceitos de Probabilidade

Sejam Ω o espaço amostral e A um evento em Ω . Então, uma função $P(\cdot)$ é denominada probabilidade se satisfaz:

- $0 \leq P(A) \leq 1, \forall A \in \Omega$
- $P(\Omega) = 1$
- Se A_1, A_2, \dots forem eventos mutuamente exclusivos, isto é, $A_i \cap A_j = \emptyset, \forall i \neq j$, então:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

Se um experimento aleatório tiver $n(\Omega)$ resultados mutuamente exclusivos e igualmente possíveis, e se um evento A conter $n(A)$ desses resultados, a probabilidade de ocorrência desse evento é definida por:

$$P(A) = \frac{n(A)}{n(\Omega)} = \frac{|A|}{|\Omega|}$$

Sejam A e B eventos em um mesmo espaço amostral, então:

- $P(\emptyset) = 0$
- $P(A) = 1 - P(A^C)$
- Se $A \subseteq B$, então $P(A) \leq P(B)$

3.1 Probabilidade Frequentista

A probabilidade de um evento é igual à sua frequência de ocorrência em um grande número de experimentos:

$$P(A) = \lim_{n \rightarrow \infty} \frac{n_A}{n}$$

, onde n_A é o número de vezes que o evento A ocorre em n experimentos.

3.2 Probabilidade de União de Dois Eventos

Para dois eventos A e B em um mesmo espaço amostral:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

3.3 Probabilidade Condicional

Sejam dois eventos A e B em um mesmo espaço amostral Ω . A probabilidade condicional de A dado que B ocorreu é definida por:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}, \quad \text{com } P(B) > 0$$

Assim, A e B são eventos independentes se, e somente se:

$$P(A \cap B) = P(A) \cdot P(B)$$

Ou equivalentemente:

$$P(A | B) = P(A) \quad \text{e} \quad P(B | A) = P(B)$$

3.4 Partições do Espaço Amostral

Os eventos B_1, B_2, \dots, B_n formam uma partição do espaço amostral Ω se:

- $B_i \cap B_j = \emptyset$, para $i \neq j$, com $i, j = 1, \dots, n$
- $\bigcup_{i=1}^n B_i = \Omega$
- $P(B_i) \geq 0$, para $i = 1, \dots, n$

Seja A um evento no espaço amostral Ω e seja B_1, \dots, B_n uma partição amostral de Ω . Podemos escrever A considerando tal partição:

$$A = \bigcup_{i=1}^n (A \cap B_i)$$

$$P(A) = P\left(\bigcup_{i=1}^n A \cap B_i\right) = \sum_{i=1}^n P(A \cap B_i)$$

Sejam B_1, B_2, \dots, B_n uma partição do espaço amostral Ω . Então, qualquer evento $A \subseteq \Omega$ pode ser escrito como:

$$P(A) = \sum_{i=1}^n P(A | B_i) \cdot P(B_i)$$

4 Teorema de Bayes

Sejam B_1, B_2, \dots, B_n uma partição do espaço amostral Ω , e A um evento com $P(A) > 0$, então:

$$P(B_i | A) = \frac{P(A | B_i) \cdot P(B_i)}{\sum_{j=1}^n P(A | B_j) \cdot P(B_j)}$$

E assim podemos definir:

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B)}$$

5 Variáveis Aleatórias

Suponha que lancemos dois dados. O espaço amostral associado ao experimento, sendo os eventos C : “sai uma cara” e R : “sai uma coroa”, é dado por:

$$\Omega = \{CC, CR, RC, RR\}$$

Uma possível variável aleatória associada ao experimento é definida por:

$$X = \text{“número de caras obtido no experimento”}$$

- Representamos variáveis aleatórias por letras maiúsculas (X, Y, Z), enquanto usamos letras minúsculas para indicar os valores das variáveis (x, y, z).
- Se o número de valores possíveis de uma variável aleatória for finito ou infinito enumerável, dizemos que é uma variável aleatória discreta.
- Caso contrário, é uma variável aleatória contínua.

A função que atribui a cada valor da variável aleatória sua respectiva probabilidade é chamada de distribuição de probabilidade:

$$P(X = x_i) = p(x_i) = p_i, \quad i = 1, 2, 3$$

A distribuição de probabilidade também é chamada de função massa de probabilidade. E temos que:

$$\sum_{i=1}^n P(X = x_i) = 1$$

Dizemos que X é uma variável aleatória contínua se existir uma função f denominada função densidade de probabilidade (fdp) que satisfaz:

- $f(x) \geq 0, \quad \forall x \in \mathbb{R}$
- $\int_{-\infty}^{\infty} f(x) dx = 1$
- $P(a \leq X \leq b) = \int_a^b f(x) dx, \quad -\infty < a < b < \infty$
- $f(x)$ é uma função com valores positivos e área unitária.

Seja X uma variável aleatória discreta ou contínua. A probabilidade condicional de que $X \in S$ dado que $X \in V$ é:

$$P(X \in S | X \in V) = \frac{P(X \in S \cap V)}{P(X \in V)}$$

, onde S e V são subconjuntos do espaço da variável.

6 Função de Distribuição

A função distribuição acumulada ou simplesmente função de distribuição de uma variável aleatória X é definida por:

$$F(x) = P(X \leq x)$$

Se discreta:

$$F(x) = \sum_{x_i \leq x} P(X = x_i)$$

Se contínua:

$$F(x) = \int_{-\infty}^x f(t) dt$$

Propriedades da função de distribuição:

- $0 \leq F(x) \leq 1$, $F(x)$ é não decrescente,
- $\lim_{x \rightarrow -\infty} F(x) = 0$, $\lim_{x \rightarrow +\infty} F(x) = 1$
- Caso discreto: $P(a < X \leq b) = F(b) - F(a)$
- Caso contínuo: $f(x) = \frac{dF(x)}{dx}$

7 Esperança

7.1 Variável Aleatória Discreta

Seja X uma variável aleatória discreta com distribuição de probabilidade $P(X = x_i)$. O valor esperado (ou esperança matemática) é:

$$E[X] = \sum_{i=1}^n x_i \cdot P(X = x_i)$$

7.2 Variável Aleatória Contínua

Seja X uma variável aleatória contínua com função densidade de probabilidade $f(x)$, então:

$$E[X] = \int_{-\infty}^{+\infty} x \cdot f(x) dx$$

7.3 Função de uma Variável Aleatória

Seja $g(X)$ uma função de uma variável aleatória discreta X . Então:

$$E[g(X)] = \sum_{i=1}^n g(x_i) \cdot P(X = x_i)$$

Seja $g(X)$ uma função de variável contínua com densidade $f(x)$. Então:

$$E[g(X)] = \int_{-\infty}^{\infty} g(x) \cdot f(x) dx$$

7.4 Propriedades

- Se $X = c$, onde c é constante, então: $E[X] = E[c] = c$
- Se c é constante: $E[cX] = c \cdot E[X]$

- Então: $E[aX + b] = a \cdot E[X] + b$

8 Momento

8.1 Momento Estatístico

Seja X uma variável aleatória discreta com valores x_1, x_2, \dots, x_k . O momento de ordem n de X é:

$$E[X^n] = \sum_{i=1}^k x_i^n \cdot P(X = x_i)$$

Se X for contínua:

$$E[X^n] = \int_{-\infty}^{\infty} x^n f(x) dx$$

8.2 Momento Central

Seja X uma variável aleatória.

- Se X é discreta, o momento central de ordem n ($n > 0$) de X é:

$$\mu_n = E[(X - E[X])^n] = \sum_{x_i} (x_i - E[X])^n \cdot P(X = x_i)$$

- Se X é contínua, então:

$$\mu_n = E[(X - E[X])^n] = \int_{-\infty}^{\infty} (x - E[X])^n \cdot f(x) dx$$

9 Variância

A variância de uma variável aleatória X é definida por:

$$V(X) = \sigma^2 = E[(X - E(X))^2]$$

O desvio padrão é igual à raiz quadrada da variância:

$$\sigma = \sqrt{V(X)}$$

Temos a propriedade de que:

$$V(X) = E[X^2] - (E[X])^2$$

Seja $g(X)$ uma função da variável aleatória X . Então,

$$V[g(X)] = E[g(X)^2] - (E[g(X)])^2$$

Seja X uma variável aleatória e a e b constantes. Então,

$$V(aX + b) = a^2 \cdot V(X)$$

10 Modelos Probabilísticos (Estocásticos) Discretos

- Os resultados de cada experimento parecem imprevisíveis, mas quando um grande número de experimentos é analisado, surge um padrão.
- Não podemos determinar o valor exato do resultado de um experimento, mas sim as probabilidades de cada resultado possível.

10.1 Distribuição Uniforme Discreta

Seja X uma variável aleatória discreta assumindo os n valores $\{a, a+c, a+2c, \dots, b-c, b\}$, com $a, b \in \mathbb{R}$, $c \in \mathbb{R}_{>0}$ e $a < b$.

Dizemos que X segue o modelo uniforme discreto se atribuímos a mesma probabilidade $1/n$ a cada um desses valores. Isto é, sua distribuição de probabilidade é dada por:

$$P(X = x) = \frac{1}{n}, \quad x = a, a+c, a+2c, \dots, b$$

onde:

$$n = 1 + \frac{b-a}{c}$$

Então,

$$\mathbb{E}[X] = \frac{a+b}{2},$$

$$V(X) = \frac{c^2(n^2-1)}{12}$$

A Figura 1 apresenta um exemplo de Distribuição Uniforme discreta.




Figura 1: Distribuição Uniforme discreta.

10.2 Distribuição de Bernoulli

Dizemos que a variável aleatória X segue o modelo de Bernoulli se atribuímos 0 à ocorrência de um fracasso ou 1 à ocorrência de um sucesso, com p representando a probabilidade de sucesso, $0 \leq p \leq 1$, e $1-p$ a probabilidade de fracasso.

A distribuição de probabilidade é dada por:

$$P(X = k) = p^k(1-p)^{1-k}, \quad k = 0, 1$$

X	0	1
$P(X = k)$	$1-p$	p

Então,

$$\mathbb{E}[X] = p,$$

$$V(X) = p \cdot (1 - p)$$

A Figura 2 apresenta um exemplo de Distribuição de Bernoulli.




Figura 2: Distribuição de Bernoulli.

10.3 Distribuição Binomial

O processo estocástico de Bernoulli possui as seguintes propriedades:

- O experimento consiste de n tentativas repetidas;
- Cada tentativa gera um resultado que pode ser classificado como sucesso ou falha;
- A probabilidade de sucesso p se mantém constante de tentativa para tentativa;
- As tentativas são feitas de forma independente uma da outra.

Seja X uma variável aleatória baseada em n repetições de um processo de Bernoulli. Então a probabilidade de obtermos k sucessos em n repetições é dada por:

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, 2, \dots, n$$

, onde:

$$C_n^k = \binom{n}{k} = \frac{n!}{(n-k)! k!}$$

é uma combinação de n elementos tomados de k em k .

Então,

$$\mathbb{E}[X] = n \cdot p,$$

$$V(X) = n \cdot p \cdot (1 - p)$$

A Figura 3 apresenta um exemplo de Distribuição Binomial.




Figura 3: Distribuição Binomial.

A seguir, apresentamos um exemplo de problema que pode ser modelado por meio da Distribuição Binomial:

“Uma urna tem 20 bolas pretas e 30 brancas. Retiram-se 25 bolas com reposição. Qual a probabilidade de que 2 sejam pretas?”

10.4 Distribuição de Poisson

O processo estocástico de Poisson possui as seguintes propriedades:

- O processo modela a ocorrência de eventos ao longo do tempo ou espaço contínuo;
- Existe uma taxa média constante $\lambda > 0$, que representa o número esperado de eventos por unidade de tempo (ou espaço);
- Os eventos ocorrem de forma independente em intervalos disjuntos;
- A probabilidade acumulada de ocorrência de eventos aumenta com o tempo.

Uma variável aleatória discreta X segue o modelo de Poisson com taxa $\lambda > 0$ se:

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k = 0, 1, 2, \dots$$

Então,

$$\mathbb{E}[X] = \lambda,$$

$$V(X) = \lambda$$

A Figura 4 apresenta um exemplo de Distribuição de Poisson.




Figura 4: Distribuição de Poisson.

A seguir, apresentamos um exemplo de problema que pode ser modelado por meio da Distribuição de Poisson:

“Numa estrada há 2 acidentes para cada 100 km. Qual a probabilidade de que em 250 km ocorram pelo menos 3 acidentes?”

10.5 Lei dos Eventos Raros

Seja X uma variável aleatória com Distribuição Binomial e p a probabilidade de sucesso. Então,

$$\lim_{n \rightarrow \infty} \binom{n}{k} p^k (1-p)^{n-k} = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k = 0, 1, 2, \dots,$$

onde $\lambda = np$ é constante.

10.6 Distribuição Geométrica

A Distribuição Geométrica modela o número de tentativas necessárias até a ocorrência do primeiro sucesso em uma sequência de experimentos de Bernoulli independentes. Suas principais características são:

- Cada tentativa resulta em um sucesso (com probabilidade p) ou uma falha (com probabilidade $1 - p$);
- As tentativas são independentes entre si;
- A variável aleatória X representa o número de tentativas até o primeiro sucesso (inclusive o sucesso), ou, equivalentemente, o número de falhas antes do primeiro sucesso.

Dizemos que a variável aleatória discreta X segue uma Distribuição Geométrica se:

$$P(X = k) = p(1-p)^{k-1}, \quad k = 1, 2, \dots$$

Então,

$$\begin{aligned} \mathbb{E}[X] &= \frac{1}{p}, \\ V(X) &= \frac{1-p}{p^2} \end{aligned}$$

A Figura 5 apresenta um exemplo de Distribuição Geométrica.




Figura 5: Distribuição Geométrica.

A seguir, apresentamos um exemplo de problema que pode ser modelado por meio da Distribuição Geométrica:

“Suponha que temos uma urna com 36 bolas, sendo 27 bolas brancas e 9 pretas. Bolas são retiradas até que uma bola preta apareça. Qual é a probabilidade de que precisaremos de mais de 6 retiradas para sortear a primeira bola preta?”

10.7 Distribuição Binomial Negativa

A Distribuição Binomial Negativa é apropriada para modelar situações em que se deseja saber a probabilidade de que um número fixo de sucessos ocorra na k -ésima tentativa, ou seja, quantas falhas ocorrem antes de alcançar um número pré-determinado de sucessos.

- Os experimentos são independentes e possuem apenas dois resultados possíveis: sucesso ou falha;
- A probabilidade de sucesso p é constante em cada tentativa;
- O processo continua até que um número fixo de sucessos seja alcançado.

Seja X o número de repetições necessárias a fim de que ocorram exatamente r sucessos, de modo que o r -ésimo sucesso ocorra na k -ésima tentativa. Então,

$$P(X = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \quad k = r, r+1, \dots$$

A Figura 6 apresenta um exemplo de Distribuição Binomial Negativa.

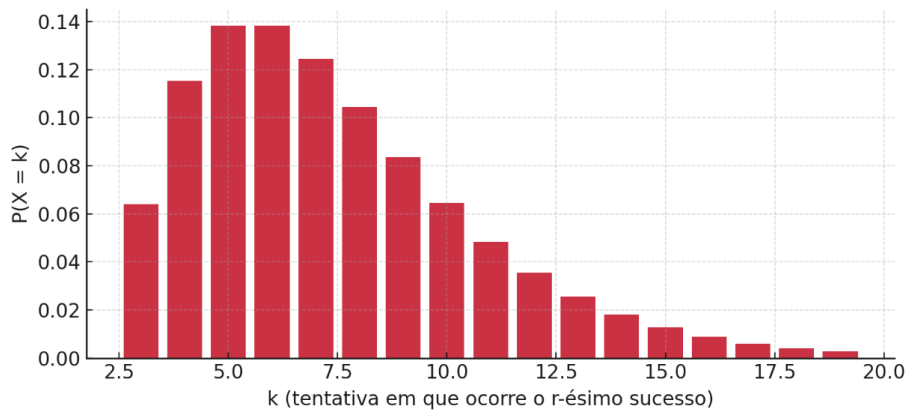


Figura 6: Distribuição Binomial Negativa.

A seguir, apresentamos um exemplo de problema que pode ser modelado por meio da Distribuição Binomial Negativa:

“Em uma série da liga de futebol amador de uma cidade, o time que ganhar quatro jogos em sete será o vencedor. Suponha que o time A tenha probabilidade $p = 0,6$ de ganhar do time B. Qual é a probabilidade de que A vença a série em seis jogos?”

10.8 Distribuição Hipergeométrica

A Distribuição Hipergeométrica é semelhante à Distribuição Binomial, porém com uma diferença essencial: as retiradas são feitas sem reposição. Enquanto a Distribuição Binomial assume que cada tentativa é independente e a probabilidade de sucesso permanece constante (devido à reposição), a Distribuição Hipergeométrica modela situações em que a probabilidade de sucesso varia a cada retirada, pois os elementos não são devolvidos ao conjunto.

Considere um conjunto de N objetos, dos quais N_1 são do tipo 1 e $N_2 = N - N_1$ são do tipo 2. Para um sorteio de n objetos ($n < N$), sem reposição, seja X a variável aleatória que define o número de objetos do tipo 1 sorteados. Então, a probabilidade de sortearmos k objetos do tipo 1 é:

$$P(X = k) = \frac{\binom{N_1}{k} \binom{N-N_1}{n-k}}{\binom{N}{n}}, \quad k = 0, 1, \dots, n$$

A Figura 7 apresenta um exemplo de Distribuição Hipergeométrica.

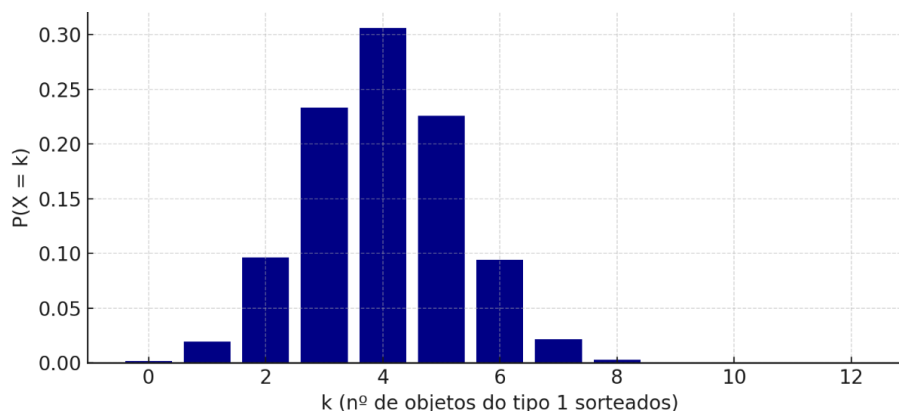


Figura 7: Distribuição Hipergeométrica.

A seguir, apresentamos um exemplo de problema que pode ser modelado por meio da Distribuição Hipergeométrica:

“Numa urna há 40 bolas brancas e 60 pretas. Retiram-se 20 bolas. Qual a probabilidade de que ocorram no mínimo 2 bolas brancas, considerando extrações sem reposição?”

11 Modelos Probabilísticos Contínuos

11.1 Distribuição Uniforme Contínua

Uma variável aleatória contínua X segue uma Distribuição Uniforme se sua função densidade de probabilidade é dada por:

$$f(x) = \begin{cases} \frac{1}{b-a}, & x \in [a, b] \\ 0, & x \notin [a, b] \end{cases}$$

Então,

$$\mathbb{E}[X] = \frac{a+b}{2},$$

$$V(X) = \frac{(b-a)^2}{12}$$

A Figura 8 apresenta um exemplo de Distribuição Uniforme contínua.




Figura 8: Distribuição Uniforme contínua.

11.2 Distribuição Normal

Uma variável aleatória contínua X que tome todos os valores na reta real segue a Distribuição Normal (ou Gaussiana) se sua função densidade de probabilidade é definida por:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{x-\mu}{\sigma} \right)^2 \right], \quad -\infty < x < \infty$$

onde $\mu = E[X]$ e $\sigma^2 = V(X) > 0$.

A Distribuição Normal apresenta as seguintes propriedades:

- $f(x)$ é simétrica em relação a μ .
- $f(x) \rightarrow 0$ quando $x \rightarrow \pm\infty$.
- O valor máximo de $f(x)$ ocorre em $x = \mu$.

Se X é uma variável aleatória contínua com distribuição normal, $X \sim \mathcal{N}(\mu, \sigma^2)$, e se $Y = aX + b$, com a e b constantes, então

$$Y \sim \mathcal{N}(a\mu + b, a^2\sigma^2).$$

Seja $X \sim \mathcal{N}(\mu, \sigma^2)$. Se

$$Z = \frac{X - \mu}{\sigma},$$

então $Z \sim \mathcal{N}(0, 1)$.

Assim,

$$\begin{aligned} P(a \leq X \leq b) &= P\left(\frac{a-\mu}{\sigma} \leq \frac{X-\mu}{\sigma} \leq \frac{b-\mu}{\sigma}\right) \\ &= P\left(\frac{a-\mu}{\sigma} \leq Z \leq \frac{b-\mu}{\sigma}\right) \\ &= P(X \leq b) - P(X \leq a). \end{aligned}$$

A tabela Normal pode ser acessada através do link https://en.wikipedia.org/wiki/Standard_normal_table#Table_examples.

A Figura 9 apresenta um exemplo de Distribuição Normal. Note que μ define o centro da curva e σ a abertura.




Figura 9: Distribuição Normal.

11.3 Distribuição Exponencial

Uma variável aleatória contínua X segue o modelo exponencial se sua função densidade de probabilidade é dada por:

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

onde $\lambda > 0$ e $-\infty < x < \infty$.

Então,

$$E[X] = \frac{1}{\lambda},$$

$$V(X) = \frac{1}{\lambda^2}$$

E a função de distribuição acumulada é dada por:

$$F(x) = \begin{cases} 1 - e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

A Distribuição Exponencial é derivada a partir de um processo de Poisson (cadeia de Markov de tempo contínuo). Ela apresenta a propriedade de “ausência de memória”, isto é:

$$P(X \geq t + s \mid X \geq s) = P(X \geq t)$$

A Figura 10 apresenta um exemplo de Distribuição Exponencial. Note que λ é onde começa o decaimento no eixo y.




Figura 10: Distribuição Exponencial.

11.4 Distribuição Gama

Uma variável aleatória contínua X tem Distribuição Gama com parâmetros $\lambda > 0$ e $\alpha > 0$, se sua função densidade de probabilidade é dada por:

$$f(x) = \begin{cases} \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0, \end{cases}$$

onde Γ é a função gama:

$$\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt.$$

Então,

$$E[X] = \frac{\alpha}{\lambda},$$

$$V(X) = \frac{\alpha}{\lambda^2}$$

Se α for um número inteiro positivo, a distribuição representará uma distribuição Erlang, ou seja, a soma de α variáveis aleatórias independentes distribuídas exponencialmente, cada uma delas com uma média $\theta = 1/\lambda$.

A Distribuição Exponencial é um caso especial da Distribuição Gama onde $\alpha = 1$.

A Figura 11 apresenta um exemplo de Distribuição Gama.



Figura 11: Distribuição Gama.

11.5 Distribuição Qui-Quadrado

A variável aleatória contínua X segue a Distribuição Qui-Quadrado (denominada χ^2) se sua função densidade de probabilidade é dada por:

$$f(x) = \begin{cases} \frac{x^{k/2-1} e^{-x/2}}{2^{k/2} \Gamma(k/2)}, & x > 0, \\ 0, & x \leq 0, \end{cases}$$

A Distribuição Qui-Quadrado é definida pela soma de k distribuições normais padronizadas e independentes. Ou seja, X tem Distribuição Qui-Quadrado com k graus de liberdade se

$$X = \sum_{i=1}^k Z_i^2,$$

onde Z_1, Z_2, \dots, Z_k são variáveis aleatórias com distribuição normal padronizada,

$$Z_i \sim \mathcal{N}(\mu = 0, \sigma^2 = 1), \quad i = 1, \dots, k.$$

Para denominar que X segue uma Distribuição Qui-Quadrado, usamos $X \sim \chi^2(k)$ ou $X \sim \chi_k^2$.

A Figura 12 apresenta um exemplo de Distribuição Qui-Quadrado.




Figura 12: Distribuição Qui-Quadrado.

11.6 Distribuição Beta

Seja X uma variável aleatória contínua limitada em $[0, 1]$. Dizemos que X segue uma Distribuição Beta se sua função densidade de probabilidade é dada por:

$$f(x) = \begin{cases} \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}, & 0 < x < 1, \\ 0, & \text{caso contrário,} \end{cases}$$

onde $\alpha, \beta > 0$ e

$$B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-u)^{\beta-1} du,$$

é a função beta, que atua como uma constante de normalização para que a área da função densidade de probabilidade seja igual a um.

A Figura 13 apresenta um exemplo de Distribuição Beta. Note que o limite onde ela é definida no eixo x é de 0 a 1.




Figura 13: Distribuição Beta.

11.7 Distribuição t de Student

A variável aleatória X tem Distribuição t de Student com ν graus de liberdade se sua função densidade de probabilidade é dada por:

$$f(x) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi} \Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}, \quad -\infty < x < \infty$$

onde Γ é a função gama:

$$\Gamma(\alpha) = \int_0^{\infty} t^{\alpha-1} e^{-t} dt$$

Quando aumentamos ν , a distribuição se aproxima da Distribuição Normal.

A Figura 14 apresenta um exemplo de Distribuição t de Student.




Figura 14: Distribuição t de Student.

11.8 Distribuição Weibull

Dizemos que a variável aleatória contínua X segue a Distribuição Weibull se:

$$f(x; \lambda, k) = \begin{cases} \frac{k}{\lambda} \left(\frac{x}{\lambda}\right)^{k-1} e^{-(x/\lambda)^k}, & x \geq 0, \\ 0, & x < 0, \end{cases}$$

Então,

$$E[X] = \lambda \Gamma \left(1 + \frac{1}{k} \right),$$

$$\text{var}[X] = \lambda^2 \left[\Gamma \left(1 + \frac{2}{k} \right) - \left(\Gamma \left(1 + \frac{1}{k} \right) \right)^2 \right]$$

A Distribuição Exponencial é um caso especial da Distribuição de Weibull onde $k = 1$.

A Figura 15 apresenta um exemplo de Distribuição Weibull.




Figura 15: Distribuição Weibull.

12 Variáveis Aleatórias Multidimensionais

12.1 Discretas

Seja ϵ um experimento aleatório associado a um espaço amostral Ω . Sejam $X_1 = X_1(\omega), X_2 = X_2(\omega), \dots$, funções que associam um número real a cada resultado $\omega \in \Omega$. Denominamos vetor aleatório o conjunto $\mathbf{X} = [X_1, X_2, \dots]$.

Sejam X e Y variáveis aleatórias associadas a um espaço amostral Ω . O par (X, Y) será uma variável aleatória discreta bidimensional se os valores possíveis forem finitos ou infinitos enumeráveis. A cada resultado possível (x_i, y_j) , $i, j = 1, 2, \dots$, associamos um número

$$p(x_i, y_j) = P(X = x_i, Y = y_j)$$

satisfazendo:

- $0 \leq P(X = x_i, Y = y_j) \leq 1 \quad \forall (x_i, y_j), i, j = 1, 2, \dots$
- $\sum_{i=1}^{\infty} \sum_{j=1}^{\infty} P(X = x_i, Y = y_j) = 1$

12.2 Contínuas

Sejam X e Y variáveis aleatórias associadas a um espaço amostral Ω . O par (X, Y) será uma variável aleatória contínua bidimensional se (X, Y) tomar todos os valores em algum conjunto não enumerável do \mathbb{R}^2 . A esse par, associamos uma função densidade de probabilidade conjunta que satisfaz:

- $f(x, y) \geq 0 \quad \forall (x, y) \in \mathbb{R}^2$
- $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$

12.3 Distribuição de Probabilidade Marginal

Seja (X, Y) uma variável aleatória discreta bidimensional. Então, a distribuição de probabilidade marginal de X é definida por:

$$P(X = x_i) = \sum_{j=1}^{\infty} P(X = x_i, Y = y_j) \quad (1)$$

e a de Y :

$$P(Y = y_j) = \sum_{i=1}^{\infty} P(X = x_i, Y = y_j) \quad (2)$$

Então a função de densidade de probabilidade marginal é dada por: As funções densidade de probabilidade marginais são dadas por:

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$$

$$f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx$$

Então:

$$P(a \leq x \leq b) = \int_a^b f_X(x) dx$$

$$P(c \leq y \leq d) = \int_c^d f_Y(y) dy$$

12.4 Probabilidade Condicional Discreta

Seja o vetor aleatório bidimensional (X, Y) . A probabilidade condicional de $X = x$ dado que $Y = y$ foi observada é dada por:

$$P(X = x | Y = y) = \frac{P(X = x, Y = y)}{P(Y = y)}, \quad P(Y = y) > 0.$$

12.5 Probabilidade Condicional Contínua

Seja (X, Y) um vetor aleatório bidimensional contínuo com função densidade de probabilidade conjunta $f(x, y)$. Sejam $f_X(x)$ e $f_Y(y)$ as funções densidade de probabilidade marginais de X e Y , respectivamente. Então, a função densidade de probabilidade condicional de X dado que $Y = y$ é definida por:

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}, \quad f_Y(y) > 0$$

e a função densidade de probabilidade condicional de Y dado que $X = x$,

$$f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)}, \quad f_X(x) > 0$$

12.6 Independência

Dizemos que as variáveis aleatórias X e Y são independentes se, e somente se:

- Caso discreto:

$$P(X = x_i, Y = y_j) = P(X = x_i)P(Y = y_j), \quad \forall i \neq j$$

- Caso contínuo:

$$f(x, y) = f_X(x)f_Y(y), \quad \forall (x, y) \in \mathbb{R}^2.$$